

Latencia de inferencia en la misma GPU

